

Perfis Epidemiológicos Explicáveis de Óbitos por Suicídio no Brasil com Análise de Classes Latentes (LCA), *CatBoost* e Inteligência Artificial Explicável (XAI)

Autores:

Miazaki, Ana Paula

Pedott, André Marcondes

Paulino, Fernando Augusto

Júnior, Braz Izaías da Silva (*Orientador*)

Faculdade de Tecnologia de Cotia (FATEC Cotia) – Centro Paula Souza

RESUMO

O suicídio constitui importante problema de saúde pública, marcado por determinantes multifatoriais e por forte heterogeneidade entre grupos populacionais. Embora fatores clínicos sejam centrais para avaliação individual de risco, bases secundárias de mortalidade, como o Sistema de Informações sobre Mortalidade (SIM), do Departamento de Informática do Sistema Único de Saúde (DATASUS), permitem investigar padrões epidemiológicos agregados em escala nacional. Este estudo teve como objetivo identificar perfis epidemiológicos de óbitos por suicídio no Brasil entre 2010 e 2024, combinando Análise de Classes Latentes (*Latent Class Analysis* – LCA), um classificador *CatBoost* treinado para reproduzir os perfis latentes e técnicas de explicabilidade, especialmente *SHAP* (*SHapley Additive exPlanations*) e *ALE* (*Accumulated Local Effects*). A base final incluiu 191.025 óbitos por lesões autoprovocadas intencionalmente, selecionados a partir dos códigos X60–X84 da Classificação Internacional de Doenças – 10ª Revisão (CID-10). A solução LCA com seis classes apresentou o melhor equilíbrio entre ajuste estatístico, separação entre classes e interpretabilidade substantiva. Em seguida, o classificador *CatBoost* reproduziu os perfis com alta fidelidade, alcançando *accuracy* de 0,9797, *balanced accuracy* de 0,9777 e *macro-F1* de 0,9781 no conjunto de teste. As análises de explicabilidade indicaram que faixa etária, região de residência, raça/cor, ocupação macro, mecanismo da lesão autoprovocada, estado civil e escolaridade foram os principais eixos de diferenciação dos perfis. Os resultados demonstram que a combinação entre LCA, *CatBoost* e inteligência artificial explicável (*Explainable Artificial Intelligence* – XAI) permite construir uma leitura epidemiológica explicável de microdados nacionais de mortalidade, deslocando o foco de uma predição clínica individual para a compreensão de padrões populacionais interpretáveis e auditáveis.

Palavras-chave: suicídio; mortalidade; análise de classes latentes; *CatBoost*; explicabilidade; *SHAP*; *ALE*; DATASUS.

ABSTRACT

Suicide is a major public health problem, characterized by multifactorial determinants and strong heterogeneity across population groups. Although clinical factors are central to individual risk assessment, secondary mortality databases such as the Brazilian Mortality Information System (SIM), maintained by the Brazilian Unified Health System Informatics Department (DATASUS) enable the investigation of aggregate epidemiological patterns at a national scale. This study aimed to identify epidemiological profiles of suicide deaths in Brazil between 2010 and 2024 by combining Latent Class Analysis (LCA), a CatBoost classifier trained to reproduce the latent profiles, and explainable artificial intelligence methods, especially SHAP (SHapley Additive exPlanations) and ALE (Accumulated Local Effects). The final dataset included 191,025 deaths due to intentional self-harm, selected according to International Classification of Diseases, 10th Revision (ICD-10), codes X60–X84. The six-class LCA solution showed the best balance between statistical fit, class separation, and substantive interpretability. Subsequently, the CatBoost classifier reproduced the latent profiles with high fidelity, achieving an accuracy of 0.9797, balanced accuracy of 0.9777, and macro-F1 of 0.9781 on the test set. Explainability analyses indicated that age group, region of residence, race/skin color, macro-occupation, mechanism of self-harm, marital status, and education were the main dimensions differentiating the profiles. The findings show that combining LCA, CatBoost, and explainable artificial intelligence (XAI) provides an explainable epidemiological reading of national

mortality microdata, shifting the focus from individual clinical prediction to interpretable and auditable population-level patterns.

Keywords: *suicide; mortality; latent class analysis; CatBoost; explainability; SHAP; ALE; DATASUS.*

1. INTRODUÇÃO

O suicídio constitui um importante problema de saúde pública em escala global, com mais de 720 mil mortes anuais, além de representar uma das principais causas de morte entre jovens de 15 a 29 anos, o que evidencia sua magnitude sanitária e social (WORLD HEALTH ORGANIZATION, 2025). No Brasil, estudos recentes mostram tendência de crescimento dos indicadores relacionados ao suicídio e às lesões autoprovocadas, com heterogeneidade entre regiões, grupos etários e sexos, reforçando a necessidade de estratégias analíticas capazes de captar padrões populacionais com maior precisão (GALVÃO; SILVA, 2023; ALVES et al., 2024; SANTOS et al., 2024).

A literatura internacional e nacional caracteriza o comportamento suicida como fenômeno multifatorial, influenciado por transtornos mentais, tentativas prévias, uso problemático de substâncias, traumas, sofrimento psíquico, vulnerabilidade social e barreiras de acesso ao cuidado em saúde mental (FAVRIL et al., 2022; SUTAR; KUMAR; YADAV, 2023; AUGUSTIN; TEIXEIRA; KÖLVES, 2025). Ao mesmo tempo, a própria Organização Mundial da Saúde (OMS) destaca que as razões associadas ao suicídio são complexas, inter-relacionadas e dependentes de contexto, o que dificulta explicações simplificadas e exige abordagens analíticas multivariadas (WORLD HEALTH ORGANIZATION, 2025).

Embora os determinantes clínicos sejam centrais para avaliação individual de risco, bases secundárias de mortalidade não foram concebidas para substituir a avaliação clínica longitudinal, mas para apoiar vigilância, gestão e análise epidemiológica de eventos letais em grande escala (BRASIL, 2025a; BRASIL, 2025b). Nesse sentido, sistemas nacionais como o Sistema de Informações sobre Mortalidade (SIM) permitem examinar dimensões demográficas, socioeconômicas, territoriais, assistenciais e circunstanciais dos óbitos, o que os torna especialmente úteis para a identificação de padrões agregados e perfis epidemiológicos (BRASIL, 2025a; BRASIL, 2025b; GALVÃO; SILVA, 2023).

Paralelamente, o uso de *machine learning* em saúde mental cresceu de forma expressiva nos últimos anos, com aplicações em diagnóstico, monitoramento, estratificação de risco e análise de linguagem, voz e registros clínicos (CRUZ-GONZALEZ et al., 2025; PIGONI et al., 2024; LIU et al., 2025). Apesar do desempenho promissor dessas abordagens, revisões recentes enfatizam desafios relacionados à validação externa, à transportabilidade dos modelos e, sobretudo, à interpretabilidade dos resultados em contextos sensíveis como o suicídio (CRUZ-GONZALEZ et al., 2025; PIGONI et al., 2024).

Nesse cenário, métodos de explicabilidade em inteligência artificial passaram a ocupar papel central, porque permitem compreender quais variáveis contribuem mais intensamente para o comportamento do modelo, em nível global e local, favorecendo transparência, auditabilidade e interpretação substantiva (LUNDBERG; LEE, 2017; MOLNAR, 2022; TJOA; GUAN, 2021). Em aplicações relacionadas ao suicídio, estudos recentes já empregaram técnicas como *SHAP* (*SHapley Additive exPlanations*) para explicar preditores dominantes em bases clínicas e tabulares, reforçando o valor da inteligência artificial explicável (*Explainable Artificial Intelligence – XAI*) para converter desempenho preditivo em conhecimento interpretável (NORDIN et al., 2023; TANG et al., 2024).

Considerando esse quadro, este estudo propõe identificar perfis epidemiológicos de óbitos por suicídio no Brasil a partir de microdados do SIM, utilizando análise de classes latentes sobre variáveis categóricas sociodemográficas e circunstanciais. A partir dessa base, busca-se construir uma etapa posterior de modelagem interpretável, na qual o *CatBoost* reproduz a estrutura latente identificada e as técnicas de *SHAP* e *ALE* (*Accumulated Local Effects*) permitem compreender quais variáveis sustentam o pertencimento aos perfis, preservando coerência epidemiológica e interpretabilidade analítica.

2. REFERENCIAL TEÓRICO

2.1. O suicídio como problema de saúde pública no Brasil

O suicídio é reconhecido pela Organização Mundial da Saúde como evento de alta relevância para a saúde pública, não apenas pelo volume absoluto de mortes, mas também por seus impactos familiares, sociais e econômicos e por sua distribuição desigual entre grupos populacionais (WORLD HEALTH ORGANIZATION, 2025). No Brasil, análises recentes apontam crescimento da mortalidade por suicídio e por lesões autoprovocadas, com marcadas diferenças por sexo, idade e território, sugerindo que a compreensão do fenômeno exige leitura simultaneamente clínica, social e epidemiológica (GALVÃO; SILVA, 2023; ALVES et al., 2024; SANTOS et al., 2024).

Estudos de revisão mostram que o comportamento suicida não decorre de um único fator causal, mas da interação entre sofrimento psíquico, transtornos mentais, tentativas prévias, uso de substâncias, experiências traumáticas, desigualdades sociais e disponibilidade de suporte e cuidado (FAVRIL et al., 2022; SUTAR; KUMAR; YADAV, 2023; AUGUSTIN; TEIXEIRA; KÖLVES, 2025). Em revisões de estudos brasileiros, também aparecem com frequência vulnerabilidades relacionadas à adolescência, juventude, populações indígenas e restrições de acesso a serviços de saúde mental, o que reforça a importância de abordagens sensíveis às heterogeneidades populacionais (AUGUSTIN; TEIXEIRA; KÖLVES, 2025).

Essa multifatorialidade torna limitada qualquer estratégia analítica que tente reduzir o suicídio a um único eixo explicativo. Por essa razão, tanto a literatura epidemiológica quanto os documentos oficiais de saúde pública defendem o fortalecimento da vigilância, da qualificação da informação e da leitura integrada de determinantes demográficos, sociais e assistenciais para subsidiar prevenção e cuidado (BRASIL, 2024; WORLD HEALTH ORGANIZATION, 2025).

2.2. Determinantes clínicos e psicossociais do comportamento suicida

Meta-análises de estudos de autópsia psicológica indicam associação robusta entre suicídio consumado e presença de transtornos mentais, sobretudo quando coexistem depressão, abuso de substâncias, sofrimento psíquico grave e histórico de comportamento suicida prévio (FAVRIL et al., 2022; SUTAR; KUMAR; YADAV, 2023). Além disso, a OMS aponta a tentativa prévia como um dos mais importantes fatores de risco para suicídio, especialmente quando combinada a crises agudas e limitações de suporte social ou de acesso ao cuidado (WORLD HEALTH ORGANIZATION, 2025).

Entretanto, o fato de esses determinantes serem centrais em nível clínico não significa que todos eles estejam disponíveis em bases secundárias de mortalidade. Sistemas de informação sobre óbito tendem a registrar com mais consistência atributos demográficos, causas de morte, local de ocorrência, circunstâncias do evento e alguns elementos de assistência ou investigação do que história psiquiátrica longitudinal, tentativas prévias, escalas psicométricas ou acompanhamento terapêutico detalhado (BRASIL, 2025b; BRASIL, 2025a).

Por isso, há uma distinção metodológica importante entre predição clínica individual de risco e caracterização epidemiológica de perfis populacionais: a primeira depende fortemente de dados clínicos ricos e longitudinalmente estruturados; a segunda pode ser conduzida com bases secundárias amplas, desde que se reconheçam suas limitações e se interpretem seus resultados como expressão de padrões agregados, e não como substitutos de avaliação clínica individual (CRUZ-GONZALEZ et al., 2025; PIGONI et al., 2024; WORLD HEALTH ORGANIZATION, 2025).

2.3. O Sistema de Informações sobre Mortalidade como base analítica

O Sistema de Informações sobre Mortalidade (SIM) foi desenvolvido no Brasil em 1975 e constitui uma das principais infraestruturas nacionais para produção de indicadores de mortalidade e análises epidemiológicas baseadas em causa básica e causas associadas de óbito (BRASIL, 2025b). Segundo a documentação oficial, o sistema reúne variáveis relacionadas à data do óbito, idade, sexo, raça/cor, situação conjugal, escolaridade, ocupação, município de residência, município de ocorrência, causas declaradas, assistência médica, necropsia,

circunstância da morte violenta e fonte da informação, entre outras, formando uma base de grande utilidade para vigilância e gestão (BRASIL, 2025a; BRASIL, 2025b).

A própria estrutura oficial do SIM mostra que campos como sexo, raça/cor, estado civil, escolaridade, ocupação, município de residência, local de ocorrência, assistência médica, necropsia, causa básica, circunstância do óbito, fonte da informação e as linhas de causas da declaração de óbito estão disponíveis para tabulação e integração analítica (BRASIL, 2025a). Em termos metodológicos, isso permite derivar indicadores temporais, territoriais, circunstanciais e assistenciais que, mesmo sem reconstituir a totalidade dos determinantes clínicos do risco suicida, oferecem base consistente para análise de perfis epidemiológicos de mortalidade (BRASIL, 2025a; BRASIL, 2025b).

Estudos brasileiros recentes têm utilizado o SIM para examinar efeitos de idade, período e coorte, tendências regionais, distribuição por sexo, idade e método utilizado, além de mudanças temporais nos padrões de mortalidade por suicídio e autolesão (GALVÃO; SILVA, 2023; ALVES et al., 2024; SANTOS et al., 2024). Essa trajetória de uso consolidado do sistema na epidemiologia do suicídio justifica sua escolha como base analítica para estudos voltados à descoberta de padrões populacionais.

2.4. *Machine learning*: conceitos básicos

Machine learning corresponde a um conjunto de métodos computacionais voltados à identificação de padrões em dados, permitindo classificar, estimar, agrupar ou apoiar a interpretação de fenômenos complexos. Segundo Mitchell (1997), um sistema de *machine learning* aprende quando seu desempenho em determinada tarefa melhora a partir da experiência observada nos dados. Em bases tabulares de saúde pública, esses métodos podem ser úteis para reconhecer estruturas populacionais, apoiar classificações e avaliar relações entre variáveis, desde que os resultados sejam interpretados à luz do contexto substantivo e das limitações da fonte de dados.

Uma distinção central em *machine learning* ocorre entre estratégias supervisionadas e não supervisionadas. Em tarefas não supervisionadas, busca-se identificar estruturas internas nos dados sem uma classe ou desfecho previamente rotulado, o que inclui abordagens de agrupamento, redução de dimensionalidade e modelagem de classes latentes (BISHOP, 2006; COLLINS; LANZA, 2010). Em tarefas supervisionadas, o modelo aprende a reproduzir uma variável-alvo conhecida a partir de variáveis preditoras observadas, sendo essa a lógica de classificadores aplicados a dados tabulares, como métodos de *gradient boosting* e o *CatBoost* (BISHOP, 2006; PROKHORENKOVA et al., 2018). Essa distinção é relevante para pesquisas que articulam descoberta de perfis populacionais e modelagem interpretável, pois permite separar a identificação de estruturas latentes da posterior reprodução, validação e explicação dessas estruturas por modelos supervisionados.

2.5. *Machine learning* aplicado ao estudo do suicídio

Revisões sistemáticas recentes mostram expansão do uso de *machine learning* em saúde mental para tarefas de diagnóstico, monitoramento, suporte à decisão e predição de desfechos relacionados ao suicídio, com aplicação em registros eletrônicos de saúde, bases psiquiátricas, dados administrativos, linguagem natural e sinais multimodais (CRUZ-GONZALEZ et al., 2025; PIGONI et al., 2024; LIU et al., 2025). Em geral, algoritmos de *ensemble* e *boosting* apresentam bom desempenho discriminativo, embora os resultados variem conforme contexto, população, qualidade do dado e estratégia de validação (LIU et al., 2025; PIGONI et al., 2024).

Ao mesmo tempo, a literatura também mostra limitações importantes. Muitos estudos operam em amostras clínicas específicas, com baixa validação externa, forte dependência de variáveis psiquiátricas dominantes e risco de perda de interpretabilidade quando se usam modelos mais complexos (CRUZ-GONZALEZ et al., 2025; PIGONI et al., 2024). Em revisão dedicada à predição de suicídio em populações psiquiátricas, a recorrência de problemas metodológicos e a necessidade de transparência e generalização foram apontadas como obstáculos centrais à adoção desses modelos em prática e política pública (PIGONI et al., 2024).

Em aplicações específicas, modelos explicáveis treinados com dados tabulares clínicos mostraram que variáveis como histórico de tentativas, ideação suicida e diagnósticos psiquiátricos tendem a aparecer entre os preditores mais relevantes, enquanto em contextos de texto e linguagem outros sinais podem emergir como importantes (NORDIN et al., 2023; TANG et al., 2024; THOMAS et al., 2025). Esses achados reforçam que o valor do uso de *machine learning*, nesse tema, não está apenas em classificar ou prever, mas em produzir interpretações coerentes com a literatura e úteis para análise substantiva (NORDIN et al., 2023; TANG et al., 2024).

2.6. Explicabilidade em inteligência artificial e interpretação de modelos tabulares

A explicabilidade em inteligência artificial consolidou-se como campo voltado a tornar modelos complexos mais transparentes, compreensíveis e auditáveis, especialmente em domínios de alto impacto, como saúde e políticas públicas (MOLNAR, 2022; TJOA; GUAN, 2021). Em termos gerais, distinguem-se explicações locais, que descrevem o comportamento do modelo para casos específicos, e explicações globais, que sintetizam padrões médios, variáveis mais influentes e relações gerais aprendidas pelo modelo (MOLNAR, 2022).

Entre os métodos de explicabilidade aplicáveis a modelos tabulares, o *SHAP* se destaca por atribuir a cada variável uma contribuição para a predição com base em valores de *Shapley*, preservando propriedades desejáveis de aditividade e consistência (LUNDBERG; LEE, 2017). Já o *ALE* permite examinar efeitos médios acumulados de variáveis em modelos preditivos, sendo especialmente útil quando há dependência entre preditores, pois reduz distorções associadas à extrapolação (APLEY; ZHU, 2020; MOLNAR, 2022). Em estudos sobre suicídio, métodos de explicabilidade ajudam a verificar se os modelos capturam sinais epidemiologicamente plausíveis ou apenas artefatos de base e de preenchimento (TANG et al., 2024; NORDIN et al., 2023).

2.7. Análise de classes latentes como estratégia de descoberta de perfis

A análise de classes latentes é uma abordagem de modelagem por mistura voltada à identificação de subgrupos não observados em uma população a partir de indicadores categóricos observáveis, estimando simultaneamente probabilidades condicionais por classe e probabilidades de pertencimento individual a cada classe (COLLINS; LANZA, 2010). Em contextos de pesquisa em saúde e ciências sociais, a técnica é particularmente útil quando o interesse recai sobre tipologias ou perfis latentes, e não sobre um desfecho contínuo único (COLLINS; LANZA, 2010).

Essa característica torna a LCA especialmente apropriada para cenários em que predominam variáveis categóricas sociodemográficas, territoriais e circunstanciais, como frequentemente ocorre em bases secundárias de mortalidade. Além disso, abordagens contemporâneas e implementações como o *StepMix* permitem ajustar modelos de mistura generalizados com variáveis externas e explorar critérios como Critério de Informação de Akaike (AIC), Critério de Informação Bayesiano (BIC), entropia e probabilidades posteriores para apoiar a escolha do número de classes e a qualidade da separação entre elas (MORIN et al., 2025; COLLINS; LANZA, 2010).

Do ponto de vista substantivo, a vantagem central da LCA neste tipo de aplicação é transformar combinações recorrentes de características observadas em perfis latentes interpretáveis, o que permite discutir heterogeneidades populacionais sem reduzir o fenômeno a médias agregadas ou a uma lógica exclusivamente preditiva. Assim, a técnica se apresenta como alternativa metodológica consistente para identificar perfis epidemiológicos de óbitos por suicídio em dados categóricos de grande escala (COLLINS; LANZA, 2010; MORIN et al., 2025).

2.8. Síntese crítica da revisão e lacuna de pesquisa

A revisão apresentada indica, de um lado, que o suicídio é multifatorial e que os principais determinantes de risco em nível individual frequentemente dependem de informação clínica rica, como histórico psiquiátrico, tentativas prévias e uso de substâncias (FAVRIL et al., 2022; SUTAR; KUMAR; YADAV, 2023). De outro, mostra que sistemas nacionais de mortalidade continuam sendo fontes centrais para vigilância e análise de padrões populacionais, justamente

por sua cobertura, padronização e disponibilidade de variáveis sociodemográficas, territoriais e circunstanciais (BRASIL, 2025a; BRASIL, 2025b; GALVÃO; SILVA, 2023).

A literatura de *machine learning*, por sua vez, mostra avanço expressivo em desempenho preditivo, mas também enfatiza a necessidade de interpretabilidade, robustez e alinhamento substantivo, especialmente em aplicações sensíveis como o suicídio (CRUZ-GONZALEZ et al., 2025; PIGONI et al., 2024; TANG et al., 2024). Nesse contexto, permanece metodologicamente relevante combinar estratégias de descoberta de perfis latentes com etapas posteriores de modelagem interpretável, deslocando o foco de uma predição clínica individual para a compreensão de padrões epidemiológicos mais amplos e explicáveis em bases públicas de mortalidade.

3. MATERIAIS E MÉTODOS



Figura 1: *Pipeline* metodológico utilizado no desenvolvimento deste estudo.

3.1. Delineamento e fonte de dados

O estudo utilizou como fonte primária o Sistema de Informações sobre Mortalidade (SIM), disponibilizado pelo Departamento de Informática do SUS (DATASUS/Ministério da Saúde), contemplando todos os óbitos não fetais ocorridos no Brasil entre 2010 e 2024. A definição de suicídio adotada seguiu a Classificação Internacional de Doenças – 10^a Revisão (CID-10), considerando como suicídios os óbitos por lesões autoprovocadas intencionalmente codificados no intervalo X60 a X84 na causa básica.

Trata-se de um estudo observacional, retrospectivo e quantitativo. O objetivo central não foi estimar risco clínico individual de suicídio, mas identificar e interpretar perfis epidemiológicos latentes de óbitos por suicídio no Brasil, a partir de características sociodemográficas, territoriais e circunstanciais registradas no SIM. Essa delimitação é importante porque os microdados de mortalidade não contêm, de forma sistemática, informações clínicas longitudinais, escalas psicométricas ou histórico individual de tentativas prévias.

Por se tratar de estudo com dados secundários, públicos, anonimizados e de acesso livre, sem identificação individual dos sujeitos, não houve necessidade de submissão ao Comitê de Ética em Pesquisa (CEP). Essa decisão está alinhada à Resolução do Conselho Nacional de Saúde (CNS) nº 510/2016, segundo a qual pesquisas que utilizam informações de acesso público, nos termos da própria norma, não são registradas nem avaliadas pelo sistema CEP/Comissão Nacional de Ética em Pesquisa (Conep) (BRASIL, 2016).

3.2. Construção do *dataset* de suicídios

Os microdados anuais do SIM foram obtidos para cada ano do período de 2010 a 2024, nos formatos compactados originais. A preparação inicial envolveu abertura, conversão e exportação dos arquivos para formato CSV (*Comma-Separated Values*), com posterior integração em ambiente *Python*. Esse procedimento permitiu padronizar os arquivos anuais e consolidar uma base nacional adequada ao processamento automático.

A partir dos arquivos CSV anuais, foi desenvolvida uma rotina em *Python* para consolidar a base nacional e isolar os óbitos cuja causa básica se encontrava no intervalo X60–X84 da CID-10. O processamento percorreu todos os arquivos do período em blocos de registros, contabilizando 20.405.974 declarações de óbito não fetal. Após a aplicação do critério de seleção por causa básica, foram identificados 191.025 óbitos por suicídio, correspondendo a aproximadamente 0,94% de todos os óbitos não fetais registrados no período.

Sobre o arquivo intermediário de suicídios, foi executado um segundo processamento com

o objetivo de tornar o *dataset* mais adequado à análise epidemiológica e à modelagem. Foram derivadas variáveis temporais, demográficas, socioeconômicas, territoriais, circunstanciais e informacionais, sem alteração do número total de registros. Nessa etapa, categorias originalmente codificadas foram recodificadas em rótulos interpretáveis, de modo a facilitar tanto a análise estatística quanto a leitura posterior dos resultados.

As rotinas analíticas foram executadas em ambiente *Python*, com uso das bibliotecas *pandas* e *NumPy* para manipulação dos dados, *scikit-learn* para particionamento e métricas, *StepMix* para estimação dos modelos de classes latentes, *CatBoost* para o classificador supervisionado, *SHAP* para explicabilidade e *matplotlib/seaborn* para visualização. Quando aplicável, foi utilizada semente aleatória 42 para favorecer a reprodutibilidade dos resultados.

3.3. Construção do perfil integrado

O perfil integrado foi definido com 12 variáveis categóricas: sexo, faixa etária, raça/cor, estado civil, escolaridade, ocupação macro, região de residência, deslocamento geográfico, local de ocorrência consolidado, mecanismo da lesão autoprovocada, indício de transtorno mental e indício de transtorno por substâncias. Esse conjunto foi selecionado para combinar ciclo de vida, posição social, contexto territorial e circunstância do evento, permitindo representar a heterogeneidade dos óbitos de maneira abrangente.

Um aspecto metodológico decisivo foi a redução de alta cardinalidade. A variável ocupação foi agregada em ocupação macro, passando a expressar grandes blocos ocupacionais, como agropecuária, construção e manutenção, indústria e produção, profissões qualificadas e serviço público, aposentado ou pensionista e estudante. O mesmo raciocínio foi aplicado a faixa etária, mecanismo da lesão autoprovocada, local de ocorrência e deslocamento geográfico. Essa recodificação reduziu fragmentação excessiva, evitou a formação de classes artificiais sustentadas por categorias raras e preservou a legibilidade epidemiológica dos perfis.

As categorias ignoradas ou não preenchidas foram preservadas como categorias analíticas explícitas, em vez de serem excluídas automaticamente. Essa decisão foi adotada porque, em sistemas de mortalidade, a ausência de informação também pode expressar características do processo de registro, da investigação do óbito ou da qualidade da informação disponível. Assim, tais categorias foram interpretadas com cautela, não como atributos individuais substantivos em si, mas como elementos relevantes para a compreensão da estrutura do dado.

3.4. Identificação dos perfis por análise de classes latentes

A escolha da Análise de Classes Latentes (*Latent Class Analysis* – LCA) decorreu da natureza do problema investigado. O conjunto de óbitos por suicídio não constitui um grupo homogêneo; ao contrário, reúne combinações heterogêneas de características sociodemográficas, contextuais e circunstanciais. Nesse cenário, o LCA permite identificar classes latentes, isto é, subgrupos não observados diretamente nos dados, mas inferidos a partir de padrões recorrentes de respostas em variáveis categóricas.

Foi ajustada uma grade de soluções com diferentes números de classes, de modo a comparar alternativas mais simples e mais complexas. A escolha da solução final considerou não apenas o ajuste estatístico, mas também a estabilidade da estimação e a utilidade interpretativa dos perfis encontrados. Desse modo, evitou-se tratar a escolha do número de classes como uma decisão exclusivamente automática, baseada em um único indicador numérico.

Foram avaliados critérios complementares. O Critério de Informação de Akaike (AIC), o Critério de Informação Bayesiano (BIC) e o Critério de Informação Bayesiano Ajustado ao Tamanho Amostral (SABIC) são medidas de ajuste penalizado: avaliam o quanto o modelo explica bem os dados sem se tornar desnecessariamente complexo, sendo que valores menores indicam soluções preferíveis. A entropia relativa indica o grau de separação entre as classes: quanto mais próxima de 1, mais nitidamente o modelo distingue os grupos. A probabilidade posterior máxima média resume quão confiante o modelo está ao atribuir cada observação à sua classe mais provável.

Também foram considerados indicadores de estabilidade estrutural. A convergência

informa se o algoritmo chegou a uma solução estável ao final da estimação. A presença de classes vazias indicaria uma solução inadequada, na qual o número de classes proposto é maior do que o efetivamente sustentado pelos dados. O tamanho relativo das classes ajuda a verificar se a solução produz perfis substantivos ou grupos residuais muito pequenos, pouco robustos e de difícil interpretação.

3.5. Construção do classificador e sentido do modelo *surrogate*

Após a identificação dos perfis latentes, foi desenvolvido um classificador multiclasse com o objetivo de reproduzir as *classes* do LCA a partir das mesmas 12 variáveis do perfil integrado. Nesse ponto, empregou-se a lógica de um modelo *surrogate*.

No contexto deste estudo, um modelo *surrogate* é um modelo supervisionado treinado para imitar, com alta fidelidade, a estrutura de classes produzida por um modelo anterior, neste caso o LCA. Em outras palavras, o LCA primeiro descobre os perfis de forma não supervisionada; em seguida, o classificador aprende a reconhecer esses perfis a partir das variáveis observadas. O modelo *surrogate* funciona, portanto, como uma aproximação preditiva da estrutura latente, permitindo investigar quais variáveis conduzem a classificação de cada perfil.

O algoritmo escolhido para essa etapa foi o *CatBoost*, método de *gradient boosting* especialmente adequado para dados tabulares com variáveis categóricas (PROKHORENKOVA et al., 2018). A base foi particionada de forma estratificada em 70,0% para treinamento, 15,0% para validação e 15,0% para teste, preservando a distribuição das classes ao longo das partições. Foram comparados cenários de treinamento com e sem ponderação pela confiança posterior máxima do LCA, a fim de verificar se essa informação adicional melhoraria a reprodução das classes.

3.6. Métricas de avaliação do classificador

A avaliação do classificador foi conduzida com métricas complementares. A *accuracy* representa a proporção total de classificações corretas, mas pode ser influenciada pelas classes mais frequentes. A *balanced accuracy* calcula a média do *recall* entre as classes, indicando se o modelo reconhece todos os perfis de forma equilibrada. O *macro-F1* resume, para cada classe, o equilíbrio entre *precision* e *recall* e depois calcula uma média simples entre todas elas, atribuindo o mesmo peso a cada perfil.

Também foram examinados os valores de *precision*, *recall* e *F1-score* por classe, bem como a matriz de confusão. Essas medidas ajudam a identificar não apenas se o modelo erra, mas entre quais perfis ele erra, aspecto relevante em um problema no qual a sobreposição entre classes pode ter significado substantivo. Como o objetivo era usar o classificador como base para explicabilidade, a avaliação buscou confirmar que o modelo reproduzia a estrutura do LCA de forma suficientemente fiel antes de interpretar suas decisões internas.

3.7. Explicabilidade com *SHAP* e *ALE*

Depois do treinamento do classificador, foi realizada uma etapa de explicabilidade com *SHAP* e *ALE*, porque o objetivo do estudo não era apenas reproduzir bem os perfis do LCA, mas compreender de maneira transparente por que cada perfil era reconhecido pelo modelo.

O *SHAP* foi empregado para decompor a predição do modelo em contribuições atribuídas a cada variável. Isso permitiu avaliar quais variáveis mais influenciam o modelo de forma global, quais são mais relevantes para distinguir uma classe específica e, em observações individuais, quais atributos impulsionam a classificação para determinado perfil. A interpretação dos valores *SHAP* foi realizada de forma associada aos nomes epidemiológicos dos perfis, evitando uma leitura puramente algorítmica das importâncias.

O *ALE* (*Accumulated Local Effects*) foi utilizado como complemento para examinar o efeito médio local de variáveis particularmente relevantes, sobretudo em situações em que há dependência estrutural entre preditores. No presente estudo, o *ALE* foi empregado principalmente para examinar o comportamento médio de variáveis ordinais relevantes, como faixa etária e escolaridade, e verificar se os efeitos aprendidos pelo classificador eram coerentes

com a leitura epidemiológica dos perfis.

4. RESULTADOS E DISCUSSÃO

4.1. Caracterização do *dataset* final

A base final reuniu 191.025 registros de óbitos por suicídio, cobrindo o período de 2010 a 2024. No perfil integrado, observou-se maior cardinalidade em ocupação macro, mecanismo da lesão autoprovocada, faixa etária e local de ocorrência consolidado. Em termos de completude, a principal limitação concentrou-se em escolaridade, seguida por estado civil e raça/cor. Também se verificou predomínio de sexo masculino, ocorrência no mesmo município, local de ocorrência em residência e mecanismo por enforcamento, estrangulamento ou sufocação, o que já sinaliza uma estrutura epidemiológica marcada, simultaneamente, por forte concentração em alguns padrões e por heterogeneidade relevante em outros.

Essa caracterização inicial é importante porque antecipa dois aspectos centrais dos resultados. Primeiro, a base apresenta padrões epidemiológicos já conhecidos na literatura, como predominância masculina e concentração de determinados mecanismos. Segundo, ela também contém variação suficiente em idade, território, ocupação, escolaridade e circunstância do evento para justificar uma abordagem de perfilamento latente, em vez de uma descrição apenas agregada.

4.2. Seleção da solução final do LCA

A comparação entre as soluções testadas mostrou queda progressiva do BIC à medida que se aumentava o número de classes, acompanhada de melhora da entropia relativa e manutenção de soluções convergentes, sem classes vazias. Esses resultados indicam que o incremento no número de classes aumentou a capacidade do modelo de representar a heterogeneidade da base sem comprometer a estabilidade da estimação.

Tabela 1: Indicadores de ajuste, separação e estabilidade das soluções LCA testadas para o perfil integrado.

K	AIC	BIC	SABIC	Entropia	Posterior médio	Classe mín. (%)	Classe máx. (%)	Converg.	Vazias
2	4.834.641	4.835.789	4.836.804	0,687	0,905	47,69	52,31	Sim	0
3	4.770.645	4.772.372	4.773.899	0,718	0,870	29,05	39,48	Sim	0
4	4.728.223	4.730.529	4.732.568	0,706	0,835	21,41	28,53	Sim	0
5	4.695.665	4.698.551	4.701.102	0,717	0,817	13,89	29,63	Sim	0
6	4.660.554	4.664.019	4.667.082	0,758	0,826	9,26	27,03	Sim	0

Fonte: Elaboração própria a partir dos artefatos do modelo LCA.




Figura 2: Seleção e estabilidade da solução de classes latentes para o perfil integrado.

Em termos interpretativos, a solução com $K=6$ apresentou o melhor equilíbrio entre ajuste, separação entre classes e utilidade epidemiológica. Embora o posterior máximo médio seja mais alto em soluções menores, a combinação entre menor BIC, entropia mais elevada e ausência de classes vazias sustenta a escolha da solução com seis classes como a mais adequada. Como sintetizado na Figura 2, essa decisão também foi reforçada pela análise substantiva dos grupos, pois a solução final produziu perfis distinguíveis e epidemiologicamente interpretáveis.

4.3. Perfis epidemiológicos identificados pelo LCA

Uma vez definida a solução com seis classes, passou-se à interpretação substantiva dos perfis. Os resultados revelaram uma tipologia heterogênea, na qual os grupos se diferenciam por idade, inserção ocupacional, posição social, território e circunstância do evento.

Para interpretar os perfis, foram calculados o *Lift vs Global*, isto é, a razão entre a presença da categoria na classe e na base total, e as probabilidades condicionais por classe. A síntese priorizou marcadores substantivos com presença mínima, evitando categorias ignoradas, não especificadas ou residuais quando havia alternativa interpretável. Assim, o Pannel C da Figura 3 apresenta um marcador por dimensão analítica, enquanto a Tabela 2 acrescenta o local de ocorrência para representar simultaneamente o meio utilizado e o local do óbito.

Tabela 2: Síntese interpretativa integrada dos perfis epidemiológicos identificados pela análise de classes latentes.

Classe	Perfil interpretativo integrado	% da base	Posterior máximo
0	Perfil <15 estudante do Norte; meio utilizado: precipitação/impacto; local: residência	12,25	0,978
1	Perfil feminino da construção/manutenção, com deslocamento para outro município da mesma UF; meio utilizado: fogo/calor/fumaça; local: estabelecimento de saúde	9,26	0,895
2	Perfil pardo agropecuário nordestino; meio utilizado: enforcamento; local: residência	24,26	0,913
3	Perfil branco em ocupações qualificadas/serviço público do Centro-Oeste; meio utilizado: precipitação/impacto; local: institucional ou coletivo	11,45	0,924
4	Perfil 75+ viúvo do Sul; meio utilizado: arma de fogo/explosivos; local: residência	15,74	0,927
5	Perfil branco industrial do Sul; meio utilizado: enforcamento; local: via pública	27,03	0,818

Fonte: Elaboração própria a partir da solução LCA final e dos marcadores selecionados por dimensão analítica.







Figura 3: Distribuição, confiança de alocação, marcadores substantivos e cardinalidade das variáveis dos perfis latentes. No Pannel C, cada barra representa um marcador substantivo selecionado por *Lift vs Global* e presença mínima na classe. O valor em “x” indica quanto a categoria é mais frequente naquele perfil em relação à base total, e o percentual indica a proporção de registros da classe que apresentam a categoria. As cores do Pannel C representam as dimensões analíticas dos marcadores: demográfica, socioeconômica/ocupacional, territorial e circunstancial.

A leitura integrada da Tabela 2 e do Painel C da Figura 3 mostra que a Classe 0 representou 12,25% da base e apresentou posterior máximo de 0,978, configurando um perfil <15, estudante e associado ao Norte, com meio utilizado por precipitação/impacto e ocorrência em residência. A Classe 1, com 9,26% da base e posterior máximo de 0,895, reuniu marcador demográfico feminino, construção/manutenção e deslocamento para outro município da mesma unidade federativa, compondo um perfil com meio utilizado por fogo/calor/fumaça e ocorrência em estabelecimento de saúde.

A Classe 2 concentrou 24,26% da base e posterior máximo de 0,913, compondo um perfil pardo, agropecuário e nordestino, com meio utilizado por enforcamento e ocorrência em residência. A Classe 3, com 11,45% da base e posterior máximo de 0,924, representou um perfil branco, inserido em ocupações qualificadas ou no serviço público e associado ao Centro-Oeste, com meio utilizado por precipitação/impacto e ocorrência em local institucional ou coletivo.

A Classe 4, com 15,74% da base e posterior máximo de 0,927, revelou um perfil idoso, com 75 anos ou mais, viúvo e associado ao Sul, com meio utilizado por arma de fogo/explosivos e ocorrência em residência. Por fim, a Classe 5, maior perfil da solução, representou 27,03% da base e apresentou posterior máximo de 0,818, sugerindo maior heterogeneidade interna, embora ainda com núcleo interpretável associado à raça/cor branca, indústria/produção, região Sul, meio utilizado por enforcamento e ocorrência em via pública.

A presença de perfis mais nítidos e de perfis mais heterogêneos reforça que o LCA não produziu apenas uma segmentação mecânica da base. Ao contrário, a solução permitiu distinguir grupos com maior coesão interna, como o perfil idoso viúvo do Sul, e grupos mais amplos, como o perfil branco industrial do Sul, cuja diversidade interna também é epidemiologicamente relevante.

4.4. Fidelidade do *CatBoost* à estrutura do LCA

A etapa seguinte consistiu em verificar se o classificador supervisionado seria capaz de reproduzir, com fidelidade, a estrutura latente gerada pelo LCA. Na comparação entre os cenários de treinamento, o Cenário A, sem ponderação por posterior máximo, apresentou o melhor desempenho e foi adotado como solução final.

Tabela 3: Particionamento da base e desempenho global do classificador *CatBoost* no conjunto de teste.

Cenário	Treino	Validação	Teste	<i>Accuracy</i>	<i>Balanced accuracy</i>	<i>Macro-F1</i>	Diagnóstico
Cenário A	70,0%	15,0%	15,0%	0,9797	0,9777	0,9781	Fidelidade muito alta

Fonte: Elaboração própria a partir do modelo *CatBoost* final.




Figura 4: Fidelidade do classificador *CatBoost* na reprodução dos perfis latentes.

Os resultados mostram que o classificador alcançou *accuracy* de 0,9797, *balanced accuracy* de 0,9777, *macro-F1* de 0,9781 e *weighted-F1* de 0,9796, indicando fidelidade muito alta à estrutura de classes do LCA. Mais importante do que o elevado desempenho global, porém, é o fato de que *balanced accuracy* e *macro-F1* também permaneceram em níveis muito altos, o que sugere que o bom desempenho não ficou restrito aos *clusters* mais prevalentes. Em termos substantivos, isso significa que o modelo conseguiu reproduzir os perfis de forma equilibrada, preservando a integridade da tipologia.

A matriz de confusão, apresentada na Figura 4, mostrou forte concentração na diagonal principal, sugerindo que os erros ocorreram em quantidade pequena e, quando presentes, tenderam a se concentrar entre perfis mais próximos. Isso é relevante porque indica não apenas alto desempenho, mas também coerência substantiva dos erros do modelo. A etapa de classificação, portanto, funcionou como ponte entre a descoberta estatística dos perfis e a interpretação explicável de suas regras de separação.

4.5. Explicabilidade global e por perfil

Uma vez estabelecida a alta fidelidade do classificador, passou-se à interpretação de sua lógica interna. Para isso, a análise global por *SHAP* permitiu identificar quais variáveis mais contribuíram, em média, para a reprodução dos perfis.




Figura 5: Explicabilidade global do classificador segundo valores *SHAP*.

Os resultados indicam que faixa etária, região de residência, raça/cor, ocupação macro e mecanismo da lesão autoprovocada foram os atributos mais influentes na estrutura de classificação do modelo. Em contraste, os indicadores de transtorno mental e transtorno por substâncias apresentaram contribuição média bastante reduzida. Essa hierarquia é coerente com os limites do SIM enquanto base de mortalidade: o sistema tende a registrar com maior robustez dimensões demográficas, territoriais e circunstanciais do que informações clínicas longitudinalmente estruturadas.

A interpretação global por *SHAP*, sintetizada na Figura 5, reforça que a diferenciação entre os perfis foi organizada principalmente por eixos de ciclo de vida, território, inserção social e circunstância do evento. Em outras palavras, o classificador não se apoiou em um único tipo de atributo, mas em uma combinação de dimensões epidemiologicamente plausíveis. Esse resultado também ajuda a qualificar o papel das variáveis clínicas indiretas: sua baixa contribuição não significa baixa relevância clínica do sofrimento psíquico, mas sim limitação do registro disponível na base secundária analisada.




Figura 6: Variáveis mais relevantes para cada perfil latente segundo *SHAP*.

A leitura por perfil, apresentada na Figura 6, aprofundou essa interpretação. Na Classe 0, destacaram-se faixa etária, ocupação macro e estado civil, o que é compatível com o perfil juvenil-estudantil. Na Classe 1, o modelo se apoiou mais em mecanismo da lesão, local de ocorrência e deslocamento geográfico, reforçando a leitura de um perfil mais circunstancial e assistencial. Na Classe 2, sobressaíram região de residência, raça/cor e ocupação macro, apoiando a interpretação territorial e ocupacional do grupo ligado à agropecuária. Na Classe 3, as variáveis mais fortes foram escolaridade e ocupação macro, reforçando a leitura de um perfil mais escolarizado e inserido em ocupações qualificadas. Na Classe 4, faixa etária, estado civil e ocupação macro sustentaram a nitidez do perfil idoso aposentado. Já na Classe 5, região de residência e ocupação macro tiveram papel importante, mostrando que, apesar de mais heterogêneo, o grupo possui núcleo territorial e ocupacional identificável.




Figura 7: Distribuição das contribuições *SHAP* por perfil latente. A escala de cor representa a codificação relativa dos valores das variáveis.

A visualização por *beeswarm*, apresentada na Figura 7, complementa as barras de importância ao mostrar a distribuição das contribuições *SHAP* dentro de cada perfil. Desse modo, torna-se possível observar não apenas quais variáveis são mais relevantes, mas também como suas contribuições se distribuem entre os registros analisados. Essa leitura é particularmente útil para verificar se determinada variável atua de forma homogênea em um perfil ou se apresenta contribuição dispersa, indicando maior heterogeneidade interna.

4.6. Interações e efeitos médios acumulados

Além das importâncias globais e por classe, o modelo também revelou que a discriminação entre perfis depende de interações entre variáveis. As combinações mais fortes envolveram idade, escolaridade, ocupação e local de ocorrência, mostrando que os perfis não são produzidos por efeitos isolados, mas por arranjos entre atributos sociais, territoriais e circunstanciais.




Figura 8: Interações globais e efeitos médios acumulados no classificador.

A Figura 8 mostra que as interações mais expressivas ocorreram entre faixa etária e escolaridade, faixa etária e ocupação macro, faixa etária e local de ocorrência consolidado, escolaridade e local de ocorrência consolidado, além de faixa etária e região de residência. Em termos epidemiológicos, esse resultado reforça a natureza multifatorial dos perfis encontrados: idade, posição social, território e circunstância do evento não operam separadamente, mas em arranjos combinados.

Como complemento, os gráficos *ALE* permitiram examinar o comportamento médio de variáveis ordinais relevantes ao longo de suas categorias. Para faixa etária, observou-se contribuição positiva das categorias mais jovens para a classe juvenil-estudantil e aumento do efeito das faixas mais elevadas para o perfil idoso. Para escolaridade, a classe associada a ocupações qualificadas mostrou efeito positivo em escolaridade superior, enquanto perfis como o agropecuário e o idoso concentraram padrões mais compatíveis com escolaridade mais baixa.

4.7. Discussão geral dos achados

Em conjunto, os resultados mostram que a combinação entre LCA, classificação supervisionada e explicabilidade foi metodologicamente consistente para o objetivo do estudo. O LCA mostrou-se adequado para descobrir perfis em uma base heterogênea e predominantemente categórica; o *CatBoost* reproduziu esses perfis com fidelidade muito alta; e *SHAP* e *ALE* permitiram compreender quais variáveis sustentaram cada classe e como seus efeitos se distribuíram ao longo da base. A camada explicativa também ajudou a distinguir perfis epidemiológicos de possíveis padrões de preenchimento do sistema, mostrando que, mesmo em classes com categorias ignoradas ou não preenchidas, o modelo continuou se apoiando em variáveis substantivas, como mecanismo, local de ocorrência, região e ocupação.

Do ponto de vista aplicado, o principal ganho do *pipeline* não está em prever individualmente quem irá cometer suicídio, mas em oferecer uma leitura estruturada e explicável de óbitos já registrados. Essa distinção é fundamental para evitar uso indevido dos resultados. O modelo não deve ser interpretado como instrumento clínico de triagem individual, mas como ferramenta analítica para vigilância, pesquisa epidemiológica e formulação de hipóteses sobre padrões populacionais.

4.8. Disponibilidade de código e materiais

O código, os *notebooks*, as figuras vetoriais e as tabelas pequenas de auditoria utilizadas na reprodução da *pipeline* estão disponíveis em: <<https://github.com/anamiazaki/perfis-epidemiologicos-explicaveis-suicidio-brasil-lca-catboost-xai>>. A base completa, os arquivos intermediários, os modelos treinados e os arquivos compactados não foram versionados diretamente por conterem microdados e artefatos computacionais grandes; a reprodução deve seguir os *scripts* e *notebooks* documentados no repositório.

4.9. Limitações e implicações

Entre as limitações do estudo, destacam-se a natureza secundária do SIM, a ausência de histórico clínico longitudinal, a possibilidade de subnotificação, a heterogeneidade regional da qualidade do preenchimento e a presença de campos ignorados ou não preenchidos em algumas variáveis. Também deve ser considerado o risco de viés ecológico: os perfis identificados descrevem padrões populacionais em registros de mortalidade e não permitem atribuir causalidade ou risco individual a pessoas com características semelhantes. Por essa razão, os resultados não devem ser interpretados como inferência causal nem como instrumento de avaliação clínica individual.

Ainda assim, a estratégia adotada mostrou potencial para apoiar vigilância epidemiológica, análise territorial e formulação de hipóteses sobre a heterogeneidade dos óbitos por suicídio no Brasil. Ao deslocar o foco de uma leitura agregada para uma tipologia explicável de perfis, o estudo oferece uma contribuição metodológica relevante para o uso responsável de inteligência artificial em saúde pública.

5. CONCLUSÃO

O estudo identificou seis perfis epidemiológicos de óbitos por suicídio no Brasil a partir de microdados do SIM referentes ao período de 2010 a 2024. A análise de classes latentes permitiu revelar subgrupos com combinações próprias de idade, ocupação, território, escolaridade e circunstância do evento. Em seguida, o classificador com *CatBoost* reproduziu esses perfis com fidelidade muito alta, permitindo que a etapa de explicabilidade tornasse visíveis os principais eixos que sustentaram cada classe.

Como contribuição metodológica, o trabalho mostra que a combinação entre LCA, um classificador supervisionado que reproduz a estrutura latente e técnicas de explicabilidade como *SHAP* e *ALE* é útil para produzir uma leitura epidemiológica mais refinada, transparente e auditável dos microdados de mortalidade. Em um tema sensível e multifatorial como o suicídio, esse encadeamento entre descoberta de perfis, reprodução preditiva e interpretação do modelo oferece um caminho mais consistente do que uma abordagem puramente descritiva ou puramente preditiva.

Em termos substantivos, os resultados indicam que os perfis de óbitos por suicídio não se organizam apenas por uma variável isolada, mas por combinações entre ciclo de vida, território, inserção ocupacional, escolaridade e circunstância do evento. Essa constatação reforça a importância de análises que tratem a heterogeneidade populacional como dimensão central do fenômeno, especialmente quando se trabalha com bases nacionais de grande escala.

Em termos aplicados, os resultados reforçam o potencial de bases públicas de mortalidade para vigilância epidemiológica e planejamento em saúde, desde que seus limites informacionais sejam reconhecidos. Os perfis identificados não substituem avaliação clínica individual, mas podem contribuir para compreender heterogeneidades populacionais e orientar investigações futuras sobre contextos, grupos e circunstâncias associados aos óbitos por suicídio no país. Assim, o estudo demonstra que métodos de inteligência artificial explicável podem ser incorporados à análise epidemiológica de bases públicas de mortalidade, desde que utilizados com finalidade populacional, interpretativa e não como instrumentos de predição clínica individual.

REFERÊNCIAS

- ALVES, F. J. O. et al. The rising trends of self-harm in Brazil: an ecological analysis of notifications, hospitalisations, and mortality between 2011 and 2022. *The Lancet Regional Health – Americas*, v. 31, p. 100691, 2024. Acesso em: 10 abr. 2026. Disponível em: <<https://doi.org/10.1016/j.lana.2024.100691>>.
- APLEY, D. W.; ZHU, J. Visualizing the effects of predictor variables in black box supervised learning models. *Journal of the Royal Statistical Society: Series B (Statistical Methodology)*, v. 82, n. 4, p. 1059–1086, 2020. Acesso em: 05 abr. 2026. Disponível em: <<https://doi.org/10.1111/rssb.12377>>.
- AUGUSTIN, L. W.; TEIXEIRA, P. R.; KÖLVES, K. Suicidality and suicide prevention in Brazil: a systematic review of reviews. *International Journal of Environmental Research and Public Health*, v. 22, n. 8, p. 1183, 2025. Acesso em: 10 abr. 2026. Disponível em: <<https://doi.org/10.3390/ijerph22081183>>.
- BISHOP, C. M. *Pattern Recognition and Machine Learning*. New York: Springer, 2006. Acesso em: 08 jun. 2026. Disponível em: <<https://link.springer.com/book/9780387310732>>.
- BRASIL. Ministério da Saúde. Conselho Nacional de Saúde. Resolução nº 510, de 7 de abril de 2016. 2016. Diário Oficial da União, Brasília, DF, 24 maio 2016. Acesso em: 10 abr. 2026. Disponível em: <<https://www.gov.br/conselho-nacional-de-saude/pt-br/atos-normativos/resolucoes/2016/resolucao-no-510.pdf/view>>.
- BRASIL. Ministério da Saúde. Secretaria de Vigilância em Saúde e Ambiente. Panorama dos suicídios e lesões autoprovocadas no Brasil de 2010 a 2021. 2024. Boletim Epidemiológico, Brasília, DF, v. 55, n. 4. Acesso em: 10 abr. 2026. Disponível em: <<https://www.gov.br/saude/pt-br/centrais-de-conteudo/publicacoes/boletins/epidemiologicos/edicoes/2024/boletim-epidemiologico-volume-55-no-04.pdf/view>>.
- BRASIL. Ministério da Saúde. Secretaria de Vigilância em Saúde. Coordenação-Geral de Informações e Análise Epidemiológicas. Dicionário de dados do SIM: tabela DO. Brasília, DF: [s.n.], 2025. Acesso em: 10 abr. 2026. Disponível em: <<https://svs.aids.gov.br/daent/cgiae/coesv/sistemas-informacao/sim/documentacao/dicionario-de-dados-SIM-tabela-DO.pdf>>.
- BRASIL. Ministério da Saúde. Sistema de Informações sobre Mortalidade. Brasília, DF: [s.n.], 2025. Acesso em: 10 abr. 2026. Disponível em: <<https://www.gov.br/saude/pt-br/composicao/svsa/sistemas-de-informacao/sim>>.
- COLLINS, L. M.; LANZA, S. T. *Latent class and latent transition analysis: with applications in the social, behavioral, and health sciences*. Hoboken: Wiley, 2010. Acesso em: 02 abr. 2026. Disponível em: <<https://doi.org/10.1002/9780470567333>>.
- CRUZ-GONZALEZ, P. et al. Artificial intelligence in mental health care: a systematic review of diagnosis, monitoring, and intervention applications. *Psychological Medicine*, 2025. Acesso em: 08 abr. 2026. Disponível em: <<https://pubmed.ncbi.nlm.nih.gov/39911020/>>.
- FAVRIL, L. et al. Risk factors for suicide in adults: systematic review and meta-analysis of psychological autopsy studies. *BMJ Mental Health*, v. 25, n. 4, p. 148–155, 2022. Acesso em: 10 abr. 2026. Disponível em: <<https://doi.org/10.1136/ebmental-2022-300549>>.
- GALVÃO, P. V. M.; SILVA, C. M. F. P. d. Analysis of age, period, and birth cohort effects on suicide mortality in Brazil and the five major geographic regions. *BMC Public Health*, v. 23, p. 1351, 2023. Acesso em: 10 abr. 2026. Disponível em: <<https://doi.org/10.1186/s12889-023-16289-0>>.
- LIU, L. et al. Predictive performance of machine learning for suicide in adolescents: systematic review and meta-analysis. *Journal of Medical Internet Research*, v. 27, p. e73052, 2025. Acesso em: 08 abr. 2026. Disponível em: <<https://doi.org/10.2196/73052>>.
- LUNDBERG, S. M.; LEE, S.-I. A unified approach to interpreting model predictions. In: *Advances in Neural Information Processing Systems*. [s.n.], 2017. Acesso em: 05 abr. 2026. Disponível em: <<https://doi.org/10.48550/arXiv.1705.07874>>.
- MITCHELL, T. M. *Machine Learning*. New York: McGraw-Hill, 1997. Acesso em: 08 jun. 2026. Disponível em: <<https://www.cs.cmu.edu/~tom/files/MachineLearningTomMitchell.pdf>>.
- MOLNAR, C. *Interpretable machine learning: a guide for making black box models explainable*. 2. ed. Christoph Molnar, 2022. Acesso em: 05 abr. 2026. Disponível em: <<https://christophm.github.io/interpretable-ml-book/>>.

- MORIN, S. et al. StepMix: a Python package for pseudo-likelihood estimation of generalized mixture models with external variables. *Journal of Statistical Software*, v. 113, n. 8, p. 1–39, 2025. Acesso em: 02 abr. 2026. Disponível em: <<https://doi.org/10.18637/jss.v113.i08>>.
- NORDIN, N. et al. An explainable predictive model for suicide attempt risk using an ensemble learning and SHAP approach. *Asian Journal of Psychiatry*, v. 79, p. 103316, 2023. Acesso em: 08 abr. 2026. Disponível em: <<https://doi.org/10.1016/j.ajp.2022.103316>>.
- PIGONI, A. et al. Machine learning and the prediction of suicide in psychiatric populations: a systematic review. *Translational Psychiatry*, v. 14, p. 140, 2024. Acesso em: 08 abr. 2026. Disponível em: <<https://doi.org/10.1038/s41398-024-02852-9>>.
- PROKHORENKOVA, L. et al. CatBoost: unbiased boosting with categorical features. In: *Advances in Neural Information Processing Systems*. [s.n.], 2018. Acesso em: 05 abr. 2026. Disponível em: <<https://arxiv.org/abs/1706.09516>>.
- SANTOS, D. R. d. et al. Perfil epidemiológico do suicídio no Brasil de 2007 a 2017. *Revista Bioética*, v. 32, p. e3055PT, 2024. Acesso em: 10 abr. 2026. Disponível em: <<https://doi.org/10.1590/1983-803420243055PT>>.
- SUTAR, R.; KUMAR, A.; YADAV, V. Suicide and prevalence of mental disorders: a systematic review and meta-analysis of world data on case-control psychological autopsy studies. *Psychiatry Research*, v. 329, p. 115492, 2023. Acesso em: 10 abr. 2026. Disponível em: <<https://doi.org/10.1016/j.psychres.2023.115492>>.
- TANG, H. et al. Analysis and evaluation of explainable artificial intelligence on suicide risk assessment. *Scientific Reports*, v. 14, p. 6163, 2024. Acesso em: 08 abr. 2026. Disponível em: <<https://doi.org/10.1038/s41598-024-53426-0>>.
- THOMAS, J. et al. An explainable artificial intelligence text classifier for suicidality prediction in youth crisis text line users: development and validation study. *JMIR Public Health and Surveillance*, v. 11, p. e63809, 2025. Acesso em: 08 abr. 2026. Disponível em: <<https://doi.org/10.2196/63809>>.
- TJOA, E.; GUAN, C. A survey on explainable artificial intelligence (XAI): toward medical XAI. *IEEE Transactions on Neural Networks and Learning Systems*, v. 32, n. 11, p. 4793–4813, 2021. Acesso em: 05 abr. 2026. Disponível em: <<https://doi.org/10.1109/TNNLS.2020.3027314>>.
- WORLD HEALTH ORGANIZATION. *Suicide*. Geneva: World Health Organization, 2025. Acesso em: 10 abr. 2026. Disponível em: <<https://www.who.int/news-room/fact-sheets/detail/suicide>>.